

Conformer と自己教師あり学習を用いた脳波からの画像カテゴリ分類

2025 年 7 月 22 日

国立陽明交通大学 工学部 電気電子工学学科

本田 果琳

1. はじめに

1.1 課題概要

本課題の目的は、被験者が画像を閲覧している際の脳波(EEG)信号に基づき、その画像が属するカテゴリ进行分类することである。

1.2 データセット

本課題では、Gifford2022EEG dataset を基に作成されたデータセットを使用した。元の 1654 クラスが、「animal, food, clothing, tool, vehicle」の 5 つの大カテゴリに集約されている点が特徴である。この変更により、モデルにはクラス間の微細な差異ではなく、より抽象的で大きな概念的カテゴリの違いを脳波信号から捉える能力が求められる。

1.3 アプローチの概要

本研究では、音声認識で高い性能を持つ Conformer モデルを脳波分析に応用する。主要なアプローチとして、以下の 3 点を導入した。

- 被験者ごとの正規化：被験者間の信号のばらつきを抑制する。
- 自己教師あり事前学習：ラベルなしデータを用いて、脳波信号の汎用的な特徴表現を獲得する。
- アンサンブル学習：性能と多様性を考慮して選定した複数モデルを組み合わせ、最終的な予測性能と頑健性を向上させる。

これらの工夫により、最終的に 52.428%の分類精度を達成した。本稿では、その開発プロセスと実験結果、そして得られた知見について詳述する。

2. ベースラインモデル：精度 38.704%

このモデルは、畳み込みブロック(Skip Connection、Batch Normalization を含む)を 2 層重ね、最後に Adaptive Average Pooling を経て分類を行う構成である。このベースラインモデルの検証データに対する Top-1 精度は 38.704%であった。

3. 提案手法：精度 52.428%

ベースラインモデルに対し、モデルアーキテクチャ、データ処理、学習戦略の各側面から改良を加えた。

3.1 モデルアーキテクチャ：Conformer

- 選定理由：脳波は音声と同様に、複雑な時間的依存関係を持つ時系列データである。そのため、局所的な特徴と大域的な文脈の両方をとらえることに長けた Conformer アーキテクチャが有効であるという仮説を立てた。
- 構造：本研究で用いたモデルは、図 1 に示すように、自己教師あり学習による Pretrain 段階と、クラス分類を行う Finetune 段階で構成される。Conformer Block は、畳み込みモジュールと Multi-Head Self-Attention モジュールを組み合わせた構造を持つ。
- Pretrain：ラベルなしデータを用い、元の信号を復元する再構成学習 (Reconstruction) と、埋め込み空間の構造を学習する対照学習 (Contrastive Learning) を同時に行うことで、汎用的な特徴表現を獲得する。
 - 損失関数の構成
 - 再構成損失(L_{recon})：モデル出力と元信号の平均二乗誤差
 - コントラスト損失($L_{contrast}$)：InfoNCE loss。⁴⁾
 - 最終損失： $L = L_{recon} + \lambda \cdot L_{contrast}$
 $\lambda = 0.1$
- Finetuning：事前学習で得られた重みを初期値とし、最終層に MLP 分類器を追加して、ラベル付きデータでモデル全体を微調整する。




図 1 提案モデルのアーキテクチャ

3.2 データ前処理

- Subject ごとの正規化：脳波信号は被験者間の個人差が非常に大きい。この個人差による分布の偏りを抑制し、モデルが汎化しやすいように、訓練データ全体ではなく、被験者 ID ごとに平均 0、分散 1 になるよう正規化を行った。睡眠脳波の研究においても有効性が報告されている。²⁾

3.3 データ拡張

- 目的：過学習を抑制し、モデルの頑健性を高めるために、以下の 5 種類のデータ拡張を確率的に使用した。
- 手法と意図
 - Temporal jittering：信号を時系列方向にランダムシフトし、時間軸の不確実性に対する耐性を高める。
 - Channel dropout：チャンネル単位を無効化し、チャンネル依存の過学習を抑制する。
 - Gaussian noise：信号にガウス雑音を加え、ノイズ耐性を強化。
 - Amplitude scaling：振幅をスケーリングし、被験者ごとの変動を模擬。
 - Time masking：入力信号のランダムな時間領域をマスキングし、情報欠損に対するロバスト性を向上。

3.4 学習戦略

- K-fold : データセットを 5 個に分割し、そのうち 4 個を訓練に、残りの 1 個を検証に用いる交差検証を 5 回繰り返した。これにより、データセットを最大限に活用し、単一の分割に依存しない評価とモデルの構築を目指した。
- アンサンブル学習 : 最終的な予測は、性能と多様性を基準に選定した 9 つのモデルの出力を平均して決定した。性能の低いモデルが悪影響を及ぼすことを避けるため、まず検証精度が 50%を超えたモデルを選定した。それに加え、過去の実験で良好な性能を示した 4 層と 6 層モデルを各 1 ずつ追加した。

- k-fold を行ったモデル

モデル番号	レイヤー数	事前学習	バッチサイズ	Learning rate	ドロップアウト
1	6	再構成学習+コントラスト学習	112	3e-5	0.18
2	4	再構成学習+コントラスト学習	128	3e-5	0.1
3	4	CLIP 学習	128	2e-5	0.15

- 他に追加したモデル(k-fold はしていない)

モデル番号	レイヤー数	事前学習	バッチサイズ	Learning rate	ドロップアウト
4	4	再構成学習+コントラスト学習	128	3e-5	0.1
5	6	再構成学習+コントラスト学習	128	4e-5	0.15

- それぞれの validation accuracy

モデル番号	fold	Validation accuracy	アンサンブルに使用したか
1	1	0.5052	○
1	2	0.5041	○
1	3	0.5082	○
1	4	0.5043	○
1	5	0.4974	×
2	1	0.5018	○
2	2	0.4966	×
2	3	0.4963	×
2	4	0.5022	○
2	5	0.4878	×
3	1	0.5008	○
3	2	0.4949	×
3	3	0.4944	×
3	4	0.4951	×
3	5	0.4900	×
4	-	0.5100	○
5	-	0.5082	○

4. 実験と考察

4.1 試作の有効性検証

ベースラインモデルから出発し、各施策を段階的に追加した際の効果を検証した。結果を表 1 に示す。

モデル/手法	検証精度(%)	向上幅(%)
ベースライン	38.704	-
+ subject ごとの正規化	38.961	+0.257
+ conformer	48.298	+9.337
+ 事前学習	50.114	+1.816
+ データ拡張	51.076	+0.962
+ k-fold+アンサンブル	51.865	+0.789
+ threshold(top-1 validation accuracy が 0.5 を超えたモデルのみを使用)	52.029	+0.164
他に二つのモデルをアンサンブル	52.428	+0.399

表 1

- 有効性に関する考察
 - Subject ごとの正規化：精度向上は限定的だが、被験者間の分布差を補正する効果が確認された。
 - Conformer：最大の精度向上要因。畳み込みによる局所的特徴と Attention による大域的文脈の抽出能力が、脳波信号の階層的な特徴構造ときわめて相性が良かったと考えられる。
 - 事前学習：自己教師あり学習により、ラベル情報なしで脳波信号の普遍的な表現を獲得できた。これにより、Finetune 時の収束が安定し、汎化性能が向上した。
 - データ拡張：モデルの頑健性を高め、過学習の抑制に有効であった。
 - K-fold アンサンブル：異なるデータ分割で学習したモデルや、アーキテクチャの異なるモデルを組み合わせることで、各モデルの予測の偏りが相殺され、最終的な精度と安定性が向上した。

4.2 精度が向上しなかった試みと考察

- ホワイトニング：脳波特有のパターンが消えてしまい、分類に有効な情報が削られた可能性が考えられる。
- Clip 学習：画像と脳波を同一空間にマッピングする CLIP 学習は、モデルが早期に過学習し、性能が不安定になる結果となった。(図 2 参照)主な原因は、画像(視覚情報)と脳波(認知情報)の間のきわめて大きなドメインギャップにあると考えられる。脳波はカテゴリを認識した結果の信号であり、画像のピクセルレベルの特徴と直接的な関係性が薄い。そのため、両者を単純に対応付けようとするモデルは、データの表面的な相関を学習してしまい、汎化性能を失ったと推測される。




図 2 自己教師あり(青)と CLIP 学習(オレンジ)の検証精度の推移

- Test Time Augmentation : 学習時にデータ拡張を導入しており、モデルはすでにある程度ノイズ耐性を獲得していたため、推論時に TTA を追加してもほとんど恩恵がなく、むしろ推論の不確実性が増えた。
- 被験者 ID embedding : 被験者 ID をベクトルとしてモデルに入力する試み。特定の被験者への過適合を招き、汎化性能が低下した。
- Weighted random sampler : クラス間の不均衡を是正するためのサンプリング手法。今回はクラスごとのサンプル数に大きな偏りがなかったと考えられる。
- モデルの複雑化 : 入力層や分類ヘッドのパラメータ数を増やし、モデルをより複雑にしたところ、性能は逆に低下した。(図 3 参照)脳波信号は多くのノイズを含んでいる。モデルの表現力が高すぎると、信号に含まれる本質的なパターンではなく、ノイズは被験者特有の癖まで過剰に学習してしまう。本データセットの規模では、モデルの複雑さがデータの本質的な複雑を上回り、過学習を招いたと考えられる。

項目	簡単なモデル	複雑化したモデル	改良の狙い
入力前処理	Conv1d(kernel=3) で直接 d_model へ投影	Conv1d(7)→BN →ReLU→ Conv1d(5)→BN →ReLU の 2 段 階プロジェクト	局所時系列特徴 の抽出強化、よ り平滑な表現
Positional encoding	学習可能パラメ	同じだが	過学習防止

	一タ(1, seq_len, d_model)	Dropout 追加	
Conformer block	4 層	同じ(4 層)	-
Pooling 層	Global Avg Pooling のみ	Global Avg + Global Max Pooling を結合	マルチスケール集約で情報損失を軽減
分類ヘッド	Linear(d_model->d_model//2->num_classes)	LayerNorm 追加・段階的 MLP(d_model*2->d_model->d_model//2->num_classes)	深い判別特徴抽出・安定化
正則化	Dropout のみ	Dropout 率の調整(0.5 倍の段階的 dropout)	汎化性能向上
Pretraining head	Reconstruction + Contrastive	同じだが dropout 適用後の特徴を使用	事前学習の安定化

表 2 複雑化したモデルの変更点




図 3 元モデル (青)と新モデル(オレンジ)の検証精度の推移

- Label smoothing/Focal loss : 損失関数に対する工夫。過学習の抑制やクラス不均衡の是正を狙ったが、本タスクにおいては Cross Entropy Loss を上回る性能は得られなかった。

5. 結論

本研究では、脳波信号からの画像カテゴリ分類という課題に取り組んだ。音声認識分野で実績のある Conformer を脳波分析に応用し、被験者ごとの正規化、自己教師あり事前学習、そしてアンサンブル学習を組み合わせることで、ベースラインを上回る 52.428% の分類精度を達成した。

実験を通じて、Conformer が脳波の局所的・大域的特徴を捉えるのにきわめて有効であること、一方で CLIP 学習のような異種モーダル間の直接的なマッピングはドメインギャップの大きさから困難であることなど、数多くの実践的な知見が得られた。改善点としては、以下の点があげられる。

- (1) より高度なマルチモーダル学習：CLIP の失敗を踏まえて、より抽象度の高いレベルで情報を統合する高度なマルチモーダルアーキテクチャを試す。
- (2) 詳細なパラメータチューニング：学習率や正則化の強度など、さらなるハイパーパラメータの探索により、モデルの性能を最大限に引き出す余地がある。

参考文献

- 1) Gulati, A., Qin, J., Chiu, C., Parmar, N., Zhang, Y., Yu, J., Han, W., Wang, S., Zhang, Z., Wu, Y., & Pang, R. (2020). Conformer: Convolution-augmented transformer for speech recognition. Interspeech 2022. <https://doi.org/10.21437/interspeech.2020-3015>
- 2) S. Hartmann and M. Baumert, "Subject-level Normalization to Improve A-phase Detection of Cyclic Alternating Pattern in Sleep EEG," 2023 45th Annual International Conference of the IEEE Engineering in Medicine & Biology Society (EMBC), Sydney, Australia, 2023, pp. 1-4, doi: 10.1109/EMBC40787.2023.10340124. keywords: {Training;Recurrent neural networks;Sleep;Sociology;Training data;Electroencephalography;Recording},
- 3) A novel data augmentation strategy for robust deep learning classification of biomedical Time-Series data: application to ECG and EEG analysis. (n.d.). <https://arxiv.org/html/2507.12645v1>
- 4) Rusak, E., Reizinger, P., Juhos, A., Bringmann, O., Zimmermann, R. S., & Brendel, W. (2024, June 28). INFONCE: Identifying the gap between theory and practice. arXiv.org. <https://arxiv.org/abs/2407.00143>
- 5) Zhang, C., Jiang, P., Hou, Q., Wei, Y., Han, Q., Li, Z., & Cheng, M. (2021). Delving deep into label smoothing. IEEE Transactions on Image Processing, 30, 5984–5996. <https://doi.org/10.1109/tip.2021.3089942>